邵伟

手机: 15888725562 | 邮箱: wei.shao@zju.edu.cn | 主页: https://7wxc.github.io/

教育背景

浙江大学（985） - 软件工程 硕士 （导师：房子荃研究员、高云君教授） 2024.09 – 2027.06

- 研究方向：数据挖掘、数据治理 主要荣誉：**国家奖学金**、浙江大学五好研究生、浙江大学优秀研究生等

东华大学（211） - 计算机科学与技术 本科 2020.09 – 2024.06

- 年级排名：2/67，绩点：4.20/5.00 主要荣誉：优秀毕业生、一等奖学金、优秀学生等

实习经历

九坤投资 - **IQuest Lab** - 大模型预训练数据算法 2026.04 – 至今

➢ **万亿级预训练语料处理与高质量数学数据定向扩源**

- 数学模式定向扩源：构建 Keyword / Query 挖掘链路，引入领域词抽取、Rethinking 校验与复杂检索扩展，驱动**长尾数学数据**的挖掘
- 通用语料定向召回：构建 fastText 和 Embedding **两阶段召回架构**，结合多样性约束与后验过滤，从 CC 和通用语料中召回数学数据
- 高频站点定向挖掘：构建**数学站点画像**，基于 Domain 聚类与页面结构等，设计通用 Schema 抽取策略，规模化补充高纯度数学语料
- 数据飞轮**闭环链路**：构建“扩源—召回—定爬—迭代”飞轮，将数据回流至扩源挖掘，并用于优化召回的多样性与长尾站点挖掘

项目成果：形成**自动化**数学数据挖掘**流水线**，累计输送 **237B Token** 的高质量数学数据，为大模型数学能力训练提供持续扩源能力

➢ **大规模数学预训练数据质量治理**

- 质量维度挖掘：基于标注、相关性、维度消融挖掘**多维数学质量评估**体系，并训练打分模型用于大规模数据过滤、排序与分级准入
- 海量数据去重：针对**千亿级**高维稀疏的预训练语料，构建 URL Dedup、Suffix Dedup、MinHash LSH 以及 SemDedup 的**分层去重框架**
- 数学评测去污：针对 GSM8K 等评测集进行 exact / fuzzy / semantic **污染去除**，过滤题面、答案与解析泄漏样本，降低评测污染风险

项目成果：落地千亿级数学预训练语料**治理体系**，构建打分、去重、去污流水线，提升数据纯度、多样性与评测可信度

➢ **高质量数学预训练数据动态配比**

- 多维数据分桶采样：基于质量、来源、内容结构对数学语料进行**细粒度分桶**，实现基于质量权重和分布约束的**桶内加权采样**
- 动态领域数据配比：基于领域、学段动态调整**桶间数据占比**，平衡高质量数据供给与长尾知识覆盖，提升不同训练阶段的数据适配
- 训练反馈闭环验证：通过 Proxy Model 和 Fast Decay 对不同桶内采样权重与桶间配比策略进行 **A/B 实验**，最大化数据组合收益

项目成果：构建数学数据**动态配比**体系，支撑数学语料按质量、领域等维度可控混合，推动领域内配比从经验设定向**反馈驱动**迭代

➢ **探索工作：**Math-aware In-context 的预训练数据组织形式探索；多语言数学预训练数据的构建与迁移探索

Bosch 集团 - **ETAS** - 嵌入式 AI 战略实习生 2024.01 – 2024.06

科研经历

One Batch Is Enough: A Unified Dataset Condensation Framework for General Time Series Analysis [Paper]

第一作者 ICML 2026 (CCF-A，AI 三大会) Poster

研究背景：传感器数据的爆炸式增长带来海量冗余，给时序模型训练造成了严峻的计算负担与存储资源瓶颈。

解决方案：提出首个**通用时序数据集浓缩**框架，设计多视图混合编码器，通过参数域、频域、拓扑域三空间对齐范式，有效捕捉时序数据的物理生成机制。在预测等 4 类主流任务、22 个数据集上验证，仅需 **0.01%训练集数据**即可保留全量数据最高 **97.9%性能**，并在三种主流架构中展现出优异泛化性。将浓缩数据应用于时序 **LLM**，仍可保留最高 **93.6%**的性能，显著提升训练效率并降低存储成本。

SHoTClean: Bridging Soft and Hard Constraints for Multivariate Time Series Cleaning [Paper]

学生一作 SIGMOD 2026 (CCF-A，数据库 Top1 会议) Oral

研究背景：多维时间序列数据常因采集误差、传感抖动等导致微小噪声波动，现有**数据清洗**方法难以在精度与效率间兼顾。

解决方案：提出一种融合**物理硬约束**与**统计软约束**的通用清洗框架，将多维时序数据清洗形式化为 **DAG 最优路径搜索问题**。研究遵循最小修复原则，提出离线批式、在线流式、在线加速以及因果增强四种核心算法。在 10 个数据集上与 10 个方法比较，准确率**最高提升 90%**，并实现了 **100×**速度提升。将框架应用于时序 **LLM** 的数据构建与预处理中，相比原始数据，MSE 误差相对下降 **8.57%**。

A Unified Federated Framework for Trajectory Data Preparation via LLMs [Paper]

学生二作 ICLR 2026 (CCF-A，AI 三大会) Poster

研究背景：现有的轨迹数据准备任务存在依赖中心化训练、任务单一、泛化性不足的局限，难以满足隐私合规与多源数据的需求。

解决方案：提出首个联邦场景下的轨迹数据准备通用框架，可在不共享原始数据的前提下统一处理 10 类轨迹治理任务。框架通过轨迹**隐私编码**生成可聚合的隐私嵌入，利用秘密共享实现安全高效的**去中心化聚合**；设计轨迹知识增强器，通过任务化提示、离线调优、**LoRA 微调**以及**双向蒸馏**，实现服务端的 LLM 与客户端的 SLM 协同学习与**跨任务泛化**；通过**联邦并行优化**策略，结合分割学习、交替冻结以及**并行训练**，降低通信与训练开销。在 6 个真实数据集上，相较 13 个基准方法在精度、效率以及可扩展性上均显著领先。

Towards Trajectory Anomaly Detection: A Fine-Grained and Noise-Resilient Framework [Paper]

第一作者 SIGKDD 2025 (CCF-A，数据挖掘顶级会议) Oral

SALT: Structural Transition-Aware Lossless Compression for Floating-Point Time Series Data Streams **SIGMOD26 在投**

REACT: A Lightweight Reliability-Aware Framework for Spatio-Temporal Out-of-Distribution Prediction **NeurIPS 26 在投**

专业技能

英语水平：CET-6（529）、雅思（6.5） **证书：**中国大学生计算机应用能力大赛国家一等奖、发明专利（两项）

学术任职：担任 ICLR26，KDD26，WWW26 会议审稿人