邵伟

手机: 15888725562 | 邮箱: wei.shao@zju.edu.cn | 主页: https://7wxc.github.io/

教育背景

浙江大学（985） - 软件工程 硕士 2024.09 – 2027.06

- 研究方向：数据挖掘、数据治理 主要荣誉：**国家奖学金 x2**、浙江大学五好研究生、浙江大学优秀研究生等

东华大学（211） - 计算机科学与技术 本科 2020.09 – 2024.06

- 年级排名：2/67，绩点：4.20/5.00 主要荣誉：优秀毕业生、一等奖学金、优秀学生等

实习经历

九坤投资 - **IQuest Lab** - 大模型预训练数据算法 2026.04 – 至今

➢ **万亿级预训练语料处理与高质量数学数据定向扩源**

背景：通用语料中高质量数学样本稀疏，长尾知识分散于小众站点，导致高质量数学文档储备不足、数据来源多样性受限

解决方案：

- 通用语料定向召回：参考 DeepSeekMath 召回思路，多轮迭代正负样本训练。使用 fastText 快速验证数据与特征收益，再将收敛数据迁移至 Embedding 模型，提升语义相关与长尾样本的召回能力。以 OOD Recall 为核心指标，在约 10% Precision 下优先保证覆盖
- 数学模式定向扩源：构建领域词抽取、复杂 Query 生成链路，从内容需求出发，借助 SERP 反向挖掘高价值 URL 与长尾数学站点
- 高频站点定向挖掘：通过 Domain 聚类挖掘高质量站点，并构建面向公式密集网页的局部渲染、OCR 识别与结果比对校验链路
- 数据飞轮迭代：打通“扩源—召回—定爬—迭代”链路，将新增数据与站点回流至扩源链路，逐轮优化召回多样性与长尾发现能力

落地成果：构建自动化数学数据挖掘流水线，累计输送 237B Token 高质量预训练语料，显著提升长尾知识点与高纯度站点的覆盖规模

➢ **大规模数学预训练数据质量治理**

背景：召回优先策略易引入伪相关、跨源重复语料，降低 Token 效率；同时，Benchmark 的广泛传播易造成评测污染，削弱可信度

解决方案：

- 多维质量评估：围绕数学相关性、完整性等维度构建多维质量标准，依据边界样本驱动标注规则自迭代，并通过维度消融验证有效质量信号。混合精编数学、普通负例与边界难例构建样本集，训练统一打分 Embedding 模型，用于海量语料过滤、排序与分级准入
- 语料去重研究：研究融合跨源优先级的 MinHash 与 SemDedup 等方案，以 URL 重复关系作为弱监督探针，扫描 Jaccard/Cosine 阈值与 LSH 分桶参数，评估重复命中率、误杀率、跨源去重率与有效 Token 保留率，确定分层去重策略
- 评测数据去污：针对主流数学评测集构建污染检测，将污染特征转化为 n-gram 黑名单，并通过阈值与规则校准平衡去污与误伤

落地成果：落地千亿级数学预训练语料的打分、去重与去污流水线，显著提升语料纯度与 Token 利用效率，有效降低评测污染风险

➢ **高质量数学预训练数据动态配比与实验验收**

背景：数学语料在领域与质量上分布差异显著，且不同数据的边际收益随训练阶段变化，难以在有限 Token 预算下最大化训练收益

解决方案：

- 多维分桶采样：基于质量、领域与内容结构细进行粒度分桶，建立可控混合空间，并随训练阶段动态调整桶内采样权重
- 动态配比迭代：根据 A/B 实验迭代配比策略，按训练阶段动态调整领域、质量间的数据供给，平衡高质量样本利用与长尾知识覆盖
- 低成本训练验收：使用 Proxy Model 降低大模型的全量实验成本，结合 Fast Decay 快速判断不同数据组合的收益趋势。围绕桶间配比、桶内采样权重与总体分布设计多组 A/B 对照实验，以下游数学评测收益和单位 Token 训练效率为统一信号筛选最优方案

落地成果：构建数学数据动态配比体系，实现语料按质量、领域等维度的可控混合，推动领域内配比从经验设定向反馈驱动迭代

➢ **探索工作：**开展 Math-aware In-context 预训练数据组织方式探索；以及多语言数学预训练数据的跨语种迁移性研究

科研经历

Wei Shao, Ziquan Fang*, Zheqi Lu, Yongfeng Su, Yuzhu Wang, Yunjun Gao. *One Batch Is Enough: A Unified Dataset Condensation Framework for General Time Series Analysis*. ICML 2026 (CCF-A, Regular Paper) **[Paper]**

Ziquan Fang*, **Wei Shao**, Zheqi Lu, Yunjun Gao. *SHoTClean: Bridging Soft and Hard Constraints for Multivariate Time Series Cleaning*. SIGMOD 2026 (CCF-A, **Oral** Paper) **[Paper]**

Wei Shao, Ziquan Fang*, Lu Chen, Yunjun Gao. *Towards Trajectory Anomaly Detection: A Fine-Grained and Noise-Resilient Framework*. SIGKDD 2025 (CCF-A, **Oral** Paper) **[Paper]**

Zhihao Zeng, Ziquan Fang*, **Wei Shao**, Lu Chen, Yunjun Gao. *A Unified Federated Framework for Trajectory Data Preparation via LLMs*. ICLR 2026 (CCF-A, Regular Paper) **[Paper]**

Yongfeng Su, Ziquan Fang*, Jihua Yang, **Wei Shao**, Yunjun Gao. *REACT: A Lightweight Reliability-Aware Framework for Spatio-Temporal Out-of-Distribution Prediction*. NeurIPS 2026 (CCF-A, Regular Paper) **[Paper]**

Zheqi Lu, Ziquan Fang*, **Wei Shao**, Yunjun Gao. *SALT: Structural Transition-Aware Lossless Compression for Floating-Point Time Series Data Streams*. VLDB 2027 (CCF-A, Under Review)

专业技能

英语水平：CET-6（529）、雅思（6.5） **学术任职：**担任 ICLR26，KDD26，WWW26 会议审稿人